



RAPPORT DE PROJET

# Ingénierie des Données & Business Intelligence

---

PROJET NORTHWIND ANALYTICS

Réalisé par :

Cherfaoui Mohamed Amine

Matricule : 232331690606

Date : 18 décembre 2025

## Résumé

Ce document présente le rapport technique du projet de Business Intelligence (BI) "**Northwind Analytics**". L'objectif de ce projet est de concevoir et mettre en œuvre une chaîne de traitement de données complète (ETL), un entrepôt de données (Data Warehouse) et des visualisations interactives pour analyser les performances commerciales (ventes, livraisons, employés).

## REMERCIEMENTS

---

Je tiens à adresser mes sincères remerciements à **Madame Mekhailia** pour les ressources pédagogiques qu'elle met à disposition à travers ses vidéos publiées sur YouTube ainsi que son site web personnel.

Ses contenus ont été particulièrement utiles pour l'installation et la configuration des différents outils nécessaires à la réalisation de ce projet de Business Intelligence, notamment l'environnement de travail, les logiciels et les dépendances techniques requises. Les explications proposées, accompagnées de démonstrations claires, m'ont permis de surmonter plusieurs difficultés liées à la mise en place de l'architecture du projet.

Par ailleurs, les informations détaillées disponibles sur son site web ont constitué un support complémentaire précieux, en offrant une vue d'ensemble structurée du projet ainsi que des indications pratiques facilitant sa compréhension et son implémentation. Ces ressources ont contribué de manière significative à la bonne réalisation du projet *Northwind Analytics*.

Je la remercie pour le partage de ces supports accessibles et pour l'effort pédagogique fourni au bénéfice des étudiants.

# Table des matières

---

|                                                         |           |
|---------------------------------------------------------|-----------|
| <b>Remerciements</b>                                    | <b>1</b>  |
| <b>1 Introduction</b>                                   | <b>3</b>  |
| <b>2 Description du Projet</b>                          | <b>3</b>  |
| <b>3 Technologies Utilisées</b>                         | <b>3</b>  |
| 3.1 Langage de Programmation et Bibliothèques . . . . . | 3         |
| 3.2 Base de Données . . . . .                           | 4         |
| <b>4 Architecture Technique</b>                         | <b>4</b>  |
| 4.1 Pipeline ETL (Extract, Transform, Load) . . . . .   | 4         |
| 4.2 Modélisation des Données . . . . .                  | 4         |
| <b>5 Fonctionnalités et Visualisation</b>               | <b>4</b>  |
| 5.1 Tableaux de Bord Interactifs . . . . .              | 5         |
| 5.2 Visualisation Avancée (3D) . . . . .                | 5         |
| <b>6 Galerie des Visualisations</b>                     | <b>6</b>  |
| <b>7 Conclusion</b>                                     | <b>10</b> |

# 1 INTRODUCTION

---

Dans le contexte actuel de prise de décision basée sur les données, ce projet vise à moderniser l'analyse de la base de données classique "Northwind". Le projet couvre l'intégralité du cycle de vie de la donnée : de l'extraction des sources brutes (fichiers Excel/Access) jusqu'à la restitution graphique via des tableaux de bord interactifs, en passant par la structuration des données dans un entrepôt SQL Server.

## 2 DESCRIPTION DU PROJET

---

Le projet se décompose en trois axes principaux :

1. **Ingénierie des Données (ETL)** : Création d'un pipeline robuste pour consolider les données hétérogènes.
2. **Modélisation (Data Warehousing)** : Conception d'un schéma en étoile optimisé pour l'analyse analytique (OLAP).
3. **Visualisation (Data Viz)** : Développement de graphiques dynamiques et 3D pour explorer les tendances.

L'architecture permet de répondre à des questions métiers telles que :

- Quels sont les produits les plus vendus par pays ?
- Quelle est la performance individuelle des employés ?
- Quelle est l'évolution temporelle des commandes et des délais de livraison ?

## 3 TECHNOLOGIES UTILISÉES

---

Le projet s'appuie sur une stack technique moderne et open-source :

### 3.1 Langage de Programmation et Bibliothèques

- **Python 3.10+** : Langage principal pour l'orchestration et le traitement.
- **Pandas** : Manipulation et transformation des dataframes (Data Cleaning).
- **PyODBC** : Connecteur pour interagir avec la base de données SQL Server.
- **Matplotlib / Seaborn** : Génération de graphiques statiques pour les rapports PDF.
- **Plotly / Plotly Express** : Création de graphiques interactifs (HTML) et visualisation 3D.

## 3.2 Base de Données

- **Microsoft SQL Server** : Système de gestion de base de données relationnelle (SGBDR) hébergeant l'entrepôt de données.
- **SQL** : Langage de requête utilisé pour la création des tables et les procédures stockées.

# 4 ARCHITECTURE TECHNIQUE

---

## 4.1 Pipeline ETL (Extract, Transform, Load)

Le script `etl_pipeline.py` orchestre le flux de données :

1. **Extract (Extraction)** : Les données brutes sont lues depuis des fichiers sources ou une base Access simulée.
2. **Transform (Transformation)** :
  - Nettoyage des valeurs nulles.
  - Renommage et standardisation des colonnes.
  - Création de dimensions (DimCustomer, DimEmployee, DimDate) et de tables de faits (FactOrders).
  - Calculs dérivés (ex : Flag "Livré/Non Livré").
3. **Load (Chargement)** : Insertion des données propres dans la base SQL Server Global\_Northwind via `database_manager.py`.

## 4.2 Modélisation des Données

Le projet utilise un modèle en étoile (*Star Schema*) pour faciliter les requêtes analytiques :

- **FactOrders** : Table centrale contenant les métriques (Quantité, Montant) et les clés étrangères.
- **Dimensions** : Tables périphériques (Clients, Employés, Temps) permettant les axes d'analyse.

# 5 FONCTIONNALITÉS ET VISUALISATION

---

Le module de visualisation (`generate_interactive_figures.py`) génère des rapports riches :

## 5.1 Tableaux de Bord Interactifs

Grâce à la librairie Plotly, les graphiques générés sont exportés en HTML interactif, permettant à l'utilisateur de zoomer, filtrer et survoler les données.

- **KPIs de Livraison** : Graphique en secteurs (Pie Chart) montrant la proportion de commandes livrées vs non livrées.
- **Analyse Géographique** : Diagrammes en barres des commandes par pays.
- **Performance Employés** : Classement des employés par volume de ventes.

## 5.2 Visualisation Avancée (3D)

Une innovation majeure du projet est l'intégration de graphiques 3D (`create_3d_scatter`), permettant de croiser trois dimensions simultanément : le Mois, le Pays et le Volume de commandes. Cela offre une perspective unique pour identifier des clusters ou des anomalies.

## 6 GALERIE DES VISUALISATIONS

Cette section présente les visualisations générées par le projet, illustrant les différents axes d'analyse explorés.




FIGURE 1 – Statut de Livraison des Commandes

*Description :* Ce graphique en camembert ("Pie Chart") offre une vue d'ensemble immédiate sur l'efficacité logistique. Il affiche la proportion des commandes livrées (en bleu) par rapport à celles qui n'ont pas encore été livrées (en rouge). C'est un KPI crucial pour surveiller les arriérés de commande.




FIGURE 2 – Total des Commandes par Pays

*Description :* Ce diagramme en barres classe les pays selon le nombre total de commandes passées. Il permet d'identifier rapidement les marchés principaux de l'entreprise (tels que les USA et l'Allemagne) et les zones géographiques où la pénétration du marché est plus faible.




FIGURE 3 – Performance des Employés (Commandes)

*Description :* Ce graphique met en avant la force de vente. Chaque barre représente un employé et la longueur indique le nombre de commandes qu'il a gérées. Cela permet de comparer la productivité individuelle et d'identifier les "top performers" de l'équipe commerciale.




FIGURE 4 – Tendence Mensuelle des Commandes

*Description :* Une analyse temporelle essentielle pour comprendre la dynamique des ventes. Cette courbe montre l'évolution du nombre de commandes mois par mois, permettant de détecter des tendances saisonnières, des pics de croissance ou des périodes de ralentissement.






FIGURE 5 – Analyse Multidimensionnelle (3D)

*Description :* Cette visualisation avancée en 3D permet une exploration complexe des données. Elle croise simultanément trois variables : le Client, l'Employé responsable et la Date (année). Chaque point représente une interaction commerciale, facilitant la détection de clusters complexes.





FIGURE 6 – Visualisation 3D - Zoom et Rotation

*Description :* Une autre perspective de l'analyse 3D, démontrant la capacité interactive de l'outil. L'utilisateur peut faire pivoter le graphique pour analyser les données sous différents angles, révélant des relations cachées entre les clients, les employés et les périodes de vente.

**FIGURE 7 – Statut de Livraison par Employé**

*Description :* Ce graphique combiné détaille le taux de succès des livraisons pour chaque employé. Il permet de voir non seulement le volume total géré, mais aussi la qualité du suivi logistique (proportion de commandes effectivement livrées vs non livrées) par responsable.

**FIGURE 8 – Statut de Livraison par Pays**

*Description :* Similaire au précédent mais axé sur la géographie, ce graphique montre les performances logistiques par destination. Il aide à repérer les pays posant des problèmes de livraison spécifiques (douanes, transporteurs locaux, etc.).

## 7 CONCLUSION

Ce projet démontre l'efficacité d'une approche programmatique moderne pour la Business Intelligence. L'automatisation du pipeline ETL via Python garantit la fiabilité et la fraîcheur des données, élément critique pour la prise de décision. Par ailleurs, l'utilisation de bibliothèques graphiques avancées comme Plotly offre une expérience utilisateur

nettement supérieure aux rapports statiques traditionnels.

L'architecture modulaire mise en place (ETL, Data Warehouse, Visualisation) assure une maintenabilité et une évolutivité optimales, permettant d'intégrer facilement de nouvelles sources de données ou de développer de nouveaux indicateurs de performance à l'avenir.